Proyecto: Automatización de ejecución - Pipeline de Predicción en GCP

1. Objetivo del Proyecto

El objetivo de este proyecto es que los alumnos implementen un **pipeline de predicción de un modelo de Machine Learning en Google Cloud Platform (GCP)**.

El pipeline tomará datos desde una tabla en **BigQuery**, realizará un proceso de **preparación de datos**, ejecutará un **modelo de Machine Learning previamente entrenado**, y almacenará las **predicciones finales en otra tabla de BigQuery**.

Durante el proyecto los alumnos aprenderán:

- Organización de arquitecturas de datos en GCP
- Uso de **BigQuery para procesamiento de datos**
- Uso de **Cloud Storage para almacenar modelos**
- Ejecución de procesos con **Python en Cloud Run**
- Configuración de **permisos entre proyectos de GCP**

---

2. Arquitectura del Proyecto

La arquitectura del proyecto se divide en **tres proyectos de GCP**, cada uno con una responsabilidad específica.

2.1 Proyecto Fuente (Datos)

Este proyecto contiene los **datos de entrada del modelo**.

Servicios a utilizar:

BigQuery

Tabla de entrada:

Tabla input que contiene los registros que serán utilizados para generar las predicciones.

El proyecto de procesamiento deberá tener **permisos de lectura** sobre esta tabla.

2.2 Proyecto de Procesamiento

Este proyecto ejecuta el **pipeline de predicción**.

Aquí se realizan:

- transformaciones de datos

- ejecución del modelo
- generación de predicciones

Servicios a utilizar:

BigQuery

Tablas temporales donde se almacenan los datos preparados para el modelo.

Cloud Storage

Bucket que almacena el modelo entrenado.

Archivo del modelo: linear_regression.joblib

Cloud Run Job

Despliegue del Cloud Run Job del Proceso Python que ejecuta la predicción utilizando el modelo.

Cloud Scheduler

Para automatizar el trigger del Cloud Run Job

2.3 Proyecto de Producción

Este proyecto contiene las **tablas finales con los resultados del modelo**. **BigQuery**

Tabla final de predicciones:

ba_modelo_propension_inscripcion

La tabla principal almacena el **histórico de predicciones del modelo**.

---

3. Pipeline de Predicción

El pipeline consta de **dos componentes principales**.

Componente 1: Extracción y Procesamiento de Datos Este

componente se encarga de:

1. Leer los datos desde **BigQuery en el proyecto fuente**
2. Aplicar transformaciones necesarias

3. Generar una **tabla temporal con las variables que usará el modelo**

Tecnología utilizada:

BigQuery SQL

Resultado del proceso:

TABLE_OUTPUT

Esta tabla contiene los datos preparados para la predicción.

Componente 2: Predicción del Modelo

Este componente ejecuta el modelo de Machine Learning.

El proceso realiza los siguientes pasos:

1. Leer los datos procesados desde BigQuery
2. Cargar el modelo desde **Cloud Storage**
3. Ejecutar la predicción
4. Guardar los resultados en **BigQuery del proyecto de producción**

Tecnología utilizada:

Python

Librerías utilizadas:

- pandas
- scikit-learn
- joblib
- google-cloud-bigquery
- google-cloud-storage

---

4. Flujo del Pipeline

El flujo completo del proceso es el siguiente:

1. Se ejecuta el proceso de **extracción y procesamiento de datos**.
2. Se genera una **tabla temporal con los datos preparados**. 3. El proceso

   Python carga el **modelo desde Cloud Storage**.

4. El modelo ejecuta las **predicciones**.
5. Los resultados se almacenan en **BigQuery en el proyecto de producción**.

---

5. Configuración de Permisos

Para que el pipeline funcione correctamente, es necesario configurar **permisos entre proyectos**.

Los alumnos deberán explicar en el proyecto:

Accesos necesarios

El proceso de procesamiento debe poder:

Leer datos del proyecto fuente Permiso:

BigQuery Data Viewer

Escribir resultados en el proyecto de producción Permiso:

BigQuery Data Editor

Leer el modelo desde Cloud Storage Permiso:

Storage Object Viewer

Los alumnos deben explicar **por qué estos permisos son necesarios para que el pipeline funcione**.

---

6. Entregable del Proyecto

Imágenes de la configuración de la SA de Vertex (permisos asignados en IAM, BigQuery y Cloud Storage), configuración del pipeline en Vertex IA (mostrar imagen del pipeline desplegado con la cuenta de servicio personalizada) y URL del repositorio del pipeline (github/gitlap).

Como deseable:

El entregable será un **video demostrativo**.

El video debe mostrar:

1. Arquitectura del proyecto Explicación

breve de:

- los tres proyectos de GCP
- qué componente existe en cada uno

---

2. Configuración de recursos Mostrar:

- datasets de BigQuery
- bucket de Cloud Storage
- modelo almacenado
- Cloud Run Job
- Cloud Scheduler

---

3. Configuración de permisos Explicar:

- qué permisos se asignaron
- entre qué proyectos
- por qué son necesarios

---

4. Ejecución del pipeline Mostrar en el

video:

1. ejecución del proceso de procesamiento de datos
2. ejecución del proceso de predicción
3. generación de resultados en la tabla final

---

5. Resultado final

Mostrar la tabla final con predicciones:

ba_modelo_propension_inscripcion y verificar que el

pipeline se ejecutó correctamente.

---

7. Resultado Esperado

Al finalizar el proyecto, los alumnos habrán construido un **pipeline funcional de predicción de Machine Learning en GCP**, que:

- lee datos desde BigQuery
- prepara los datos para el modelo
- ejecuta un modelo almacenado en Cloud Storage

- genera predicciones
- almacena resultados en BigQuery